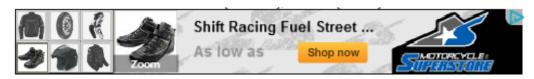


EMC Forum

8 novembre 2011

Julien SIMON, VP Engineering

On s'est déjà vu, non?

















Criteo

- Société française fondée en 2005
- Leader mondial du reciblage personnalisé
- 1200 clients dans 20 pays
- Chiffre d'affaires 2011: \$200 millions
- 400 collaborateurs, dont 100 en R&D



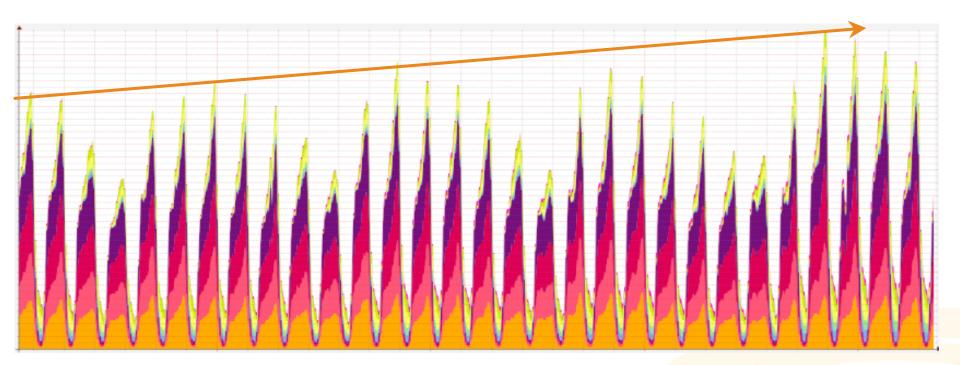
Le reciblage personnalisé





Volumétrie

- Des centaines de millions de bannières livrées par jour
- Pic supérieur à 1 million de bannières par minute
- Croissance de 25% en 1 mois





Sous le capot

- Chaque visite d'un internaute sur un site annonceur génère de nombreux événements
 - Produits vus, cliqués, ajoutés au panier, achetés
 - Données spécifiques au domaine (ex: date d'un voyage)
- Chaque affichage d'une bannière sur un site éditeur génère de nombreux événements
 - Format de la bannière
 - Annonceur et produits présentés
 - Clic et produit cliqué
- Tous ces événements sont reçus et stockés par Criteo
- Leur analyse nous permet de prédire les taux de clic et de recommander des produits
- Volumétrie : plusieurs téraoctets supplémentaires par jour



Architecture v1

- Ecriture des événements sur chaque serveur web
- Consolidation sur des serveurs backoffice
- Analyse & agrégation par des applications internes
- Stockage des résultats agrégés dans des SGBDR

Davantage de trafic, davantage de serveurs web

- ★ Consolidation de plus en plus longue et fragile
- Explosion des besoins en stockage sur les serveurs
- Durée de traitement en forte hausse
- Pression accrue sur les bases de données
- → Obstacles à la montée en charge de la plate-forme



Architecture v2

- Collecte des événements web sur des serveurs syslog
- Stockage long terme sur un cluster Isilon X200
- Analyse & agrégation sur un cluster Hadoop/Hive
- Stockage des résultats agrégés dans des SGBDR, mais aussi dans MongoDB ou dans memcached/membase
- → Infrastructure découpée en couches claires
- → Standardisation et optimisation des configurations
- → Mutualisation des ressources de stockage
- → Mutualisation des ressources de calcul
- → « Scale-out » à tous les étages



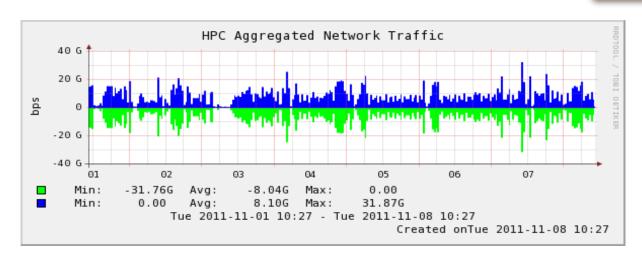
Hadoop cluster

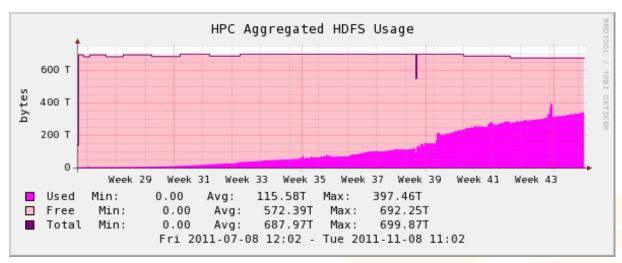
Network traffic

8 Gbit/s average 32 Gbit/s peak

HDFS storage

from 0 to 366 TB in 4 months







Isilon cluster



Write thoughput for 8 nodes: over 3 Gbit/s



Pourquoi Isilon?

- Expériences positives depuis 2006
 - Mise en production facile, administration légère
 - Montée en charge démontrée au-delà du Pétaoctet
 - Bonnes performances
 - Culture R&D
- Isilon convient bien à notre contexte
 - Architecture « scale-out »
 - Données non structurées
 - Croissance rapide et imprévisible de la volumétrie
 - Besoin d'avoir un débit élevé en lecture/écriture
 - Possibilité d'intégrer des applications tierces sur le cluster



Des questions?



http://www.criteo.com http://labs.criteo.com

